

Tarso Bertolini
Mariana de Castro

FORMAÇÃO DE EFEITO BOLHA INFORMACIONAL
EM AMBIENTES DIGITAIS BASEADOS EM
ALGORITMOS DE RECOMENDAÇÃO
- PROJETO DE PESQUISA CIENTÍFICA -

Projeto de Pesquisa apresentada na disciplina de
Métodos de Pesquisa Científica do curso de Ciência
da Computação.

Curitiba
2025

CAPÍTULO 1 - INTRODUÇÃO

1.1 Contexto da Pesquisa e Problemática

A revolução digital e a popularização de plataformas online transformaram profundamente a maneira como as informações são consumidas e compartilhadas. Redes sociais, mecanismos de busca, serviços de streaming e aplicativos de notícias utilizam algoritmos de recomendação para personalizar a experiência do usuário, selecionando conteúdos com base em seu histórico de interações, preferências e comportamentos passados (PARISER, 2011). Embora essa personalização promova maior engajamento e satisfação individual, ela também pode levar à formação de filter bubbles (bolhas de filtro) – ambientes digitais nos quais os usuários são expostos predominantemente a informações que reforçam suas visões pré-existentes, limitando o contato com perspectivas divergentes (SUNSTEIN, 2017).

O fenômeno das filter bubbles está intrinsecamente ligado ao conceito de echo chambers (câmaras de eco), onde ideias são amplificadas e repetidas dentro de um grupo homogêneo, sem a devida exposição a opiniões contrárias (JAMIESON; CAPPELLA, 2008). Essa dinâmica tem implicações significativas para a sociedade, especialmente no que diz respeito à polarização política, à fragmentação do debate público e à erosão do consenso democrático (FLAXMAN; GOEL; RAO, 2016). Estudos empíricos demonstram que usuários de redes sociais como Facebook e Twitter têm menor probabilidade de encontrar conteúdos ideologicamente diversos quando a curadoria é feita por algoritmos (BAKSHY; MESSING; ADAMIC, 2015). Além disso, pesquisas recentes indicam que esses sistemas podem reproduzir e amplificar vieses sociais, desde discriminação em aplicativos de namoro (KNIBBS, 2023) até a segmentação política em plataformas de notícias (ARIDOR et al., 2019).

Apesar do crescente corpo de evidências sobre os efeitos negativos das filter bubbles, persistem lacunas importantes na literatura. Uma delas é a escassez de estudos longitudinais que analisem os impactos cumulativos da exposição prolongada a ambientes algorítmicos homogêneos (TRAN et al., 2014). Outra lacuna relevante é a falta de generalização dos resultados, uma vez que muitos estudos concentram-se em plataformas específicas (como o Sina Weibo, analisado por LI et al., 2019), dificultando comparações mais amplas. Além disso, embora existam propostas teóricas para mitigar o problema – como a diversificação forçada de recomendações (ZHU; CHENG, 2018) e a introdução de elementos de randomização (GHARAHIGHEHI; VENS, 2021) –, poucas soluções foram implementadas em larga escala ou avaliadas em termos de eficácia prática (LIU, 2024).

Diante desse cenário, este projeto de pesquisa busca investigar de forma sistemática como os algoritmos de recomendação contribuem para a formação e o reforço de filter bubbles, bem como explorar estratégias para reduzir seus efeitos negativos. A relevância do tema é amplificada pelo papel central que essas plataformas desempenham na formação de opinião pública e na dinâmica social contemporânea. Ao compreender melhor os mecanismos que sustentam as bolhas informacionais, será possível propor intervenções mais eficazes, seja no nível técnico (modificações nos algoritmos), regulatório (políticas de transparência) ou educacional (alfabetização midiática).

1.2 Objetivos

Objetivo Geral:

Analisar o impacto dos algoritmos de recomendação na formação de filter bubbles e echo chambers, avaliando seus efeitos sobre a diversidade informacional.

Objetivos Específicos:

1. Identificar os mecanismos pelos quais os algoritmos de recomendação contribuem para a criação de filter bubbles e echo chambers.

2. Avaliar os efeitos sociais e cognitivos dessas bolhas informacionais, com foco em polarização e diversidade de conteúdo.

Questão de Pesquisa:

Como os algoritmos de recomendação influenciam a formação de bolhas informacionais?

CAPÍTULO 2 - REVISÃO DA LITERATURA

2.1 Algoritmos de Recomendação e a Formação de Filter Bubbles

Os algoritmos de recomendação são sistemas computacionais projetados para prever as preferências dos usuários e sugerir conteúdos relevantes com base em seu comportamento passado (JANNACH et al., 2010). Esses sistemas são amplamente utilizados em plataformas digitais, como redes sociais (Facebook, Twitter), serviços de streaming (Netflix, Spotify) e agregadores de notícias (Google News), onde desempenham um papel central na curadoria de informações (NGUYEN; HUI, 2014). Apesar de sua eficácia em aumentar o engajamento, pesquisas indicam que eles podem contribuir para a formação de filter bubbles – ambientes digitais nos quais os usuários são predominantemente expostos a conteúdos que reforçam suas visões pré-existentes, com pouca diversidade informacional (PARISER, 2011).

Dois mecanismos principais explicam esse fenômeno:

1. **Personalização baseada em homofilia** – Algoritmos de recomendação tendem a priorizar conteúdos semelhantes aos que o usuário já consumiu, reforçando padrões de homofilia (atração por ideias similares). Estudos empíricos mostram que, em redes sociais, usuários com inclinações políticas específicas recebem predominantemente notícias alinhadas a suas preferências, reduzindo a exposição a perspectivas opostas (BAKSHY et al., 2015).
2. **Otimização para engajamento** – Plataformas digitais frequentemente priorizam métricas como tempo de tela e cliques, levando algoritmos a recomendar conteúdos mais extremos ou emocionalmente carregados, que geram maior interação (HOSSEINMARDI et al., 2021). Essa dinâmica pode

amplificar a polarização, como demonstrado em pesquisas sobre o Twitter (DUSKIN et al., 2024).

Além disso, trabalhos como o de CHITRA e MUSCO (2019) utilizam modelagem matemática para demonstrar como sistemas de recomendação podem criar ciclos de retroalimentação (feedback loops), nos quais pequenos vieses iniciais são amplificados ao longo do tempo, consolidando ainda mais as bolhas informacionais.

2.2 Impactos Sociais e Cognitivos das Echo Chambers

A formação de "echo chambers" (câmaras de eco) – espaços onde opiniões são repetidas e reforçadas sem contrapontos – tem sido associada a diversos efeitos negativos, tanto em nível individual quanto coletivo.

Efeitos Individuais

- Polarização cognitiva – A exposição contínua a conteúdos homogêneos pode levar ao endurecimento de opiniões e à redução da capacidade crítica. Um estudo experimental de KNOBLOCH-WESTERWICK e WESTERWICK (2023) demonstrou que usuários com alta autoestima tendem a buscar informações que validem suas crenças, ignorando visões dissonantes.
- Viés de confirmação – Algoritmos que reforçam preferências existentes exacerbam a tendência humana a buscar e valorizar informações que confirmem suas opiniões (LORD et al., 1979).

Efeitos Coletivos

- Fragmentação do debate público – Plataformas como Facebook e YouTube foram acusadas de contribuir para a divisão política, como observado durante eleições nos EUA e no Brasil (FLAXMAN; GOEL; RAO, 2016).
- Amplificação de desinformação – Conteúdos sensacionalistas ou falsos muitas vezes se espalham mais rapidamente em ambientes algorítmicos, onde a verificação de fatos é negligenciada em favor do engajamento (VOSOUGHI et al., 2018).

Limitações dos Estudos Existentes

Embora a literatura seja vasta, algumas lacunas persistem:

- **Falta de estudos longitudinais** – A maioria das pesquisas analisa dados pontuais, sem acompanhar múltiplos testes (TRAN et al., 2014).
- **Generalização limitada** – Muitos estudos focam em plataformas específicas (ex.: LI et al., 2019 analisou o Weibo), dificultando comparações amplas.

CAPÍTULO 3 - MÉTODO DE PESQUISA

3.1 Caracterização da pesquisa

Esta pesquisa de natureza quantitativa e experimental utiliza métodos de análise algorítmica e desenvolvimento de software para medir indicativos de formação de filter bubbles. O estudo segue a abordagem de Design Science Research (DSR), com as seguintes adaptações em relação ao plano original:

1. **Plataformas analisadas:** Devido a restrições de acesso a APIs privadas ou pagas (Twitter, Instagram e TikTok), o estudo concentrou-se nas plataformas YouTube e Reddit, que disponibilizam APIs públicas para pesquisa acadêmica.
2. **Natureza dos resultados:** As métricas obtidas são indicadores numéricos de similaridade e diversidade de conteúdo, não constituindo uma medida absoluta do fenômeno de filter bubbles, mas fornecendo evidências comparativas entre plataformas.

A escolha metodológica justifica-se pela necessidade de não apenas entender o fenômeno, mas propor um instrumento prático para quantificá-lo, alinhando-se a trabalhos como os de HANNAK et al. (2017) e KLIMAN-SILVER et al. (2015), que desenvolveram métricas para avaliação de personalização em algoritmos.

3.2 Planejamento da pesquisa

3.2.1 Desenvolvimento da Ferramenta (Artefato)

Foi desenvolvido um artefato em Python para coletar e analisar recomendações de plataformas selecionadas (ex.: Youtube, Reddit, com as seguintes funcionalidades:

Coleta de Dados:

- YouTube Data API v3 para recomendações de vídeos
- Reddit API (PRAW) para posts populares em subreddits

Métricas de Personalização:

- **Índice de Similaridade de Conteúdo:** Medida baseada em cosine similarity para comparar recomendações consecutivas.
- **Diversidade Temática:** Contagem de tópicos distintos sugeridos em um intervalo de tempo (ex.: usando NLP para classificação de temas).
avg_similarity.
- **Taxa de Reforço Algorítmico:** Frequência com que conteúdos semelhantes reaparecem após interações do usuário.

Limitações Técnicas:

Impossibilidade de acesso a APIs de Twitter, Instagram e TikTok por serem:

Totalmente privadas (Instagram)

Com acesso pago (Twitter API v2)

Sem API pública oficial (TikTok)

Restrições de coleta:

YouTube: 100 requisições/dia (cota gratuita)

Reddit: 60 requisições/minuto

Visualização de Dados:

Geração de gráficos (via **matplotlib** ou **plotly**) para representar o grau de personalização ao longo do tempo.

3.2.2 Validação Experimental**Seleção de Plataformas:**

Foco no Youtube e no Reddit, dada a especificação técnica e disponibilidade das API's.

Amostragem:

- Perfis simulados (com histórico de interações controlado) e perfis reais (via voluntários, com consentimento).
- Divisão em grupos com comportamentos distintos (ex.: usuários que consomem conteúdo político variado vs. homogêneo).

Análise Estatística:

PLATAFORMA	SIMILARIDADE MÉDIA	DIVERSITY SCORE
Youtube	0.09 ± 0.03	0.91 ± 0.03
Reddit	0.006 ± 0.001	0.994 ± 0.001

Interpretação:

O Reddit apresentou diversidade quase máxima (**0.994**), sugerindo menor tendência à formação de bolhas

O YouTube mostrou moderada similaridade (**0.09**), indicando forte tendência à repetição de conteúdos

Estes valores são indicativos e devem ser interpretados como:

Sinais de potencial formação de bolhas (YouTube)

Referência de diversidade algorítmica (Reddit)

3.3 Aspectos Éticos

Riscos e Mitigações

- Todos os dados coletados são públicos e não identificáveis pois foram realizados testes simulados
- As APIs foram acessadas dentro dos limites de uso aceitável e não houve quebra de uso regulamentado.
- Não houve interação com perfis pessoais ou dados sensíveis quaisquer.

CAPÍTULO 4 - CRONOGRAMA

4.1 Fases e Atividades

SEMANA	ATIVIDADES	ENTREGAS
12 a 18/05/2025	Definição final do método e revisão do protocolo de pesquisa. - Configuração do ambiente de desenvolvimento (Python, bibliotecas, APIs).	- Protocolo de pesquisa revisado. - Ambiente de desenvolvimento configurado.
19 a 25/05/2025	- Desenvolvimento inicial da ferramenta (coleta de dados via APIs/scraping).	- Script básico de coleta de dados. - TCLE aprovado.
26/05 a 01/06/2025	Coleta de dados em plataformas selecionadas (Youtube, Reddit). - Testes preliminares com perfis simulados.	- Dataset inicial estruturado. - Relatório parcial de coleta.
02 a 08/06/2025	- Implementação das métricas (similaridade, diversidade temática). - Análise estatística dos dados coletados.	- Código das métricas implementado. - Resultados preliminares de análise.
09 a 15/06/2025	- Validação dos resultados com dados obtidos do artefato em python. - Redação do relatório final (seções: resultados, discussão).	- Relatório dos dados obtidos. - Relatório final.

16 a 18/06/2025	Ajustes finais na ferramenta e relatório. - Gravação do vídeo-pôster.	- Ferramenta funcional entregue. - Relatório e vídeo finalizados.
------------------------	--	--

4.1 Fases e Atividades

- Semanas 1-2 (Planejamento e Desenvolvimento Inicial):

A fase inicial garante a base técnica (ferramenta) e ética (TCLE) para a pesquisa, alinhando-se com diretrizes de Design Science Research (HEVNER et al., 2004).

- Semanas 3-4 (Coleta e Análise):

A coleta de dados em múltiplas plataformas segue metodologias validadas em estudos como os de HANNAK et al. (2017), enquanto a análise estatística utiliza técnicas consolidadas (API's públicas, web scraping com python).

- Semanas 5-6 (Validação e Finalização):

A validação com os dados obtidos pelo artefato assegura a robustez dos resultados, e a redação do relatório segue padrões acadêmicos (normas USP).

REFERÊNCIAS BIBLIOGRÁFICAS

ARIDOR, G.; GONCALVES, D.; SIKDAR, S. Deconstructing the Filter Bubble: User Decision-Making and Recommender Systems. arXiv preprint arXiv:1904.10527, 2019. Disponível em: <https://arxiv.org/abs/1904.10527>.

BAKSHY, E.; MESSING, S.; ADAMIC, L. A. Exposure to ideologically diverse news and opinion on Facebook. *Science*, v. 348, n. 6239, p. 1130-1132, 2015. DOI: 10.1126/science.aaa1160.

BERMAN, R.; KATONA, Z. Curation Algorithms and Filter Bubbles in Social Networks. *Marketing Science*, v. 39, n. 2, p. 296-316, 2020. Disponível em: <https://pubsonline.informs.org/doi/abs/10.1287/mksc.2019.1208>.

CHITRA, U.; MUSCO, C. Understanding Filter Bubbles and Polarization in Social Networks. arXiv preprint arXiv:1906.08772, 2019. Disponível em: <https://arxiv.org/abs/1906.08772>.

DUSKIN, K. et al. Echo Chambers in the Age of Algorithms: An Audit of Twitter's Friend Recommender System. arXiv preprint arXiv:2404.06422, 2024. Disponível em: <https://arxiv.org/abs/2404.06422>.

FLAXMAN, S.; GOEL, S.; RAO, J. M. Filter Bubbles, Echo Chambers, and Online News Consumption. *Public Opinion Quarterly*, v. 80, n. S1, p. 298-320, 2016. DOI: 10.1093/poq/nfw006.

GHARAHIGHEHI, A.; VENS, C. Diversification in Session-based News Recommender Systems. arXiv preprint arXiv:2102.03265, 2021. Disponível em: <https://arxiv.org/abs/2102.03265>.

HANNAK, A. et al. Measuring Personalization of Web Search. arXiv preprint arXiv:1706.05011, 2017. Disponível em: <https://arxiv.org/abs/1706.05011>.

HEVNER, A. R. et al. Design Science in Information Systems Research. MIS Quarterly, v. 28, n. 1, p. 75-105, 2004. DOI: 10.2307/25148625.

HOSSEINMARDI, H. et al. The Interaction between Political Typology and Filter Bubbles in News Recommendation Algorithms. In: Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, p. 130-140, 2021. DOI: 10.1145/3442188.3445893.

JANNACH, D. et al. Recommender Systems: An Introduction. Cambridge: Cambridge University Press, 2010.

JAMIESON, K. H.; CAPPELLA, J. N. Echo Chamber: Rush Limbaugh and the Conservative Media Establishment. Oxford: Oxford University Press, 2008.

KNOBLOCH-WESTERWICK, S.; WESTERWICK, A. Algorithmic personalization of source cues in the filter bubble: Self-esteem and self-construal impact information exposure. New Media & Society, v. 25, n. 1, p. 45-67, 2023. DOI: 10.1177/14614448211027963.

LI, K. G. et al. Does Algorithmic Filtering Create a Filter Bubble? Evidence from Sina Weibo. Academy of Management Proceedings, v. 2019, n. 1, p. 14168, 2019. DOI: 10.5465/AMBPP.2019.14168abstract.

NGUYEN, T.; HUI, P.-M. Modeling Opinion Formation under Algorithmic Filtering. arXiv preprint arXiv:1407.0014, 2014. Disponível em: <https://arxiv.org/abs/1407.0014>.

PARISER, E. The Filter Bubble: What the Internet Is Hiding from You. New York: Penguin Press, 2011.

SUNSTEIN, C. R. #Republic: Divided Democracy in the Age of Social Media. Princeton: Princeton University Press, 2017.

TRAN, T. et al. Exploring the Filter Bubble. In: Proceedings of the 23rd International Conference on World Wide Web, p. 677-686, 2014. DOI: 10.1145/2566486.2568012.

ZHU, Q.; CHENG, Z. Methods for Enhancing Recommendation Diversity. Journal of Information Science, v. 44, n. 5, p. 682-695, 2018. DOI: 10.1177/0165551517747305.